社会媒体云计算

朱文武 崔 鹏 王 智
清华大学

关键词：社会媒体 云计算 在线社会网络

引言

在线社会网络是目前互联网上最流行的应用之一，是人们访问各种多媒体内容的重要平台，拥有海量的用户和内容。但是目前互联网的存储量与计算体系结构已经不能满足超大规模社会化多媒体数据管理与计算的要求。云计算（cloud computing）的出现为社会媒体服务提供了新思路。作为一种新兴技术，云计算的目的是通过互联网提供各种计算服务和存储服务，包括“基础设施即服务（infrastructure as a service，IaaS）”、“平台即服务（platform as a service，PaaS）”和“软件即服务（software as a service，SaaS）”等。面对日益增长的媒体数据，我们需要搭建支持大规模存储和运算的基础体系平台，搜集、集成互联网上的有效信息，挖掘潜在知识，同时提高各种算法的可扩展性，使之能够应用于大规模运算。与传统的分布式计算相比，云计算在海量数据的聚融分析、挖掘和信息组织管理方面更加高效。社会网络中巨大的用户规模和海量的社会化多媒体数据，将催生新一代互联网基础平台。在社会网络的驱动下，适应大规模社会化多媒体数据密集计算的基础平台将成为互联网领域的下一个制高点。

社会媒体计算的应用及挑战

社会媒体计算的应用

在线社会网络记录了用户、内容以及关系等数据。基于这些数据的社会媒体计算向人们提供了多种应用，包括以下三个方面。

传播预测 在社会网络中，传播预测可以预测内容扩散的速度、规模和影响程度，从而帮助内容优化或广告定向[1]。社会化媒体的信息传播依托于复杂的虚拟社会网络，虚拟社会网络信息的传播特征与传统社会网络（即真实社会中的社会网络）有相通之处。针对传统社会网络，社会学研究界提出了多种不同的理论，例如：针对信息传播的二级传播理论，针对用户行为的弱连接优势理论和强连接优势理论，以及利用社会网络结构对个性进行分析的结构洞理论。在线社会网络中，多媒体内容来源于真实的Web数据，为了分析和预测多媒体内容在社会网络中的传播，一方面需要考虑社会网络本身的拓扑结构，包括节点类型、边权重信息和拓扑动态性等；另一方面还要考虑多媒体内容本身的特性对社会传播的影响，进一步建立影响力和传播预测模型。传播预测依赖于社会网络拓扑和内容分析，需要强大的计算资源的支持。

内容推荐与搜索 在社会网络中，人们可以获得丰富的多媒体数据。在种类繁多、数量巨大的社会化媒体内容中，进行内容推荐和搜索是实现社会化媒体价值的关键。在社会媒体推荐和搜索中，传统算法面临困难：现实社会媒体中用户关联的多维性和异构性，以及社会网络中大规模用户的高阶关联及隐含关联特性，给内容推荐与搜索带来了巨大挑战[2]。如何对社会网络中的社会关系、用户行为进行建模，以及如何利用用户当前的地域、好友状况等上下文[3]，有针对性地做好社会化媒体推荐和搜索服务，依赖于对社会网络中大规模用户、内

容以及关系数据的挖掘和分析。

舆情分析 在社会网络中，有大量的新闻媒体参与，为社会网络用户提供了丰富的内容服务。然而，社会网络也可以成为不良信息的传播工具。由于社会网络中信息的传播没有中心，内容的传播和分享仅依赖于端到端的社会关系，难以监控。不良信息在社会网络中出现后，其传播的速度和影响的规模比历史上任何媒体速度都更快、规模都更大。因此，社会媒体中的舆情分析对社会网络监管、国家安全具有重要意义。社会网络舆情分析的目的在于及时发现特定话题，并进行监控和预测，以及对话题的信息加以疏导。要达到此目的需依赖于对社会数据的提取、挖掘以及相应的预测模型，需要建立在强大的存储、网络和计算平台之上。

社会媒体计算面临的挑战

社会媒体计算应用面临的挑战包含两方面：与计算相关的数据挖掘，以及与通信相关的社会媒体的部署和传输。

社会媒体数据挖掘面临的挑战

为了实现在线社会媒体应用，需要对社会网络中的用户、内容和关系等重要信息进行深度挖掘，从而从海量的原始数据中总结和归纳出与具体应用有关的信息和知识，建立社会网络数据与用户之间的联系。

大规模用户和内容数据 在线社会网络拥有海量用户和内容，例如，Facebook目前拥有大约10亿活跃用户[12]，如果这些用户每天生成的照片冲洗出来，堆起来的高度相当于80个埃菲尔铁塔。如此大规模的用户量和内容量是传统多媒体服务平台难以处理的。同时，在社会网络中，这些用户和内容并不是孤立的，它们通过社会关系和用户的各种活动联系起来，进一步增加了社会媒体中数据挖掘的难度。如何实现对社会网络中海量用户和内容的信息挖掘是社会媒体计算的基础。

实时数据生成 在社会网络中，数据由用户实时生成。例如，在YouTube网站，每分钟大约会有60小时的视频播放数据被上传[4]。实时数据生成对数据挖掘提出了巨大的挑战，因为大量用户通常要求获得“新”内容（新闻、娱乐信息等），要求数据处理平台能够及时发现和推送实时媒体内容。在实时数据处理中，需要解决数据的快速定位、获取以及计算等问题。

动态社会网络结构 社会网络的形成本质是用户交互行为，包括用户对社会关系的创建、维护和更新，以及用户对内容的生成和传播等。用户对用户的作用以及用户对内容的操作具有很强的动态性，在这种动态环境中，数据挖掘一方面需要设计合适的数据结构和计算模型，根据社会网络的动态性进行更新；另一方面需要设计可动态配置的计算平台，优化资源利用。

社会媒体数据部署与传输面临的挑战

社会媒体应用最终通过网络分发给用户。在线社会网络的发展对用户如何使用多媒体的影响急剧扩大，内容分发也从传统的由网络中心向网络边缘分发的模式（内容提供商—用户），逐渐演变成媒体内容在网络边缘传播，在网络中心做归档存储的模式（用户—用户）[6]。在这种模式下，传统的内容部署策略面临巨大的挑战。

社会媒体内容的生成和传播消耗巨大资源 在线社会网络中，多媒体的内容由用户生成，并且通过用户间的关系链进行传播。这种传播模式具有病毒式快速和突发传播的特性。例如，2011年女足世界杯期间，Twitter每秒钟记录了超过 7000条关于该主题的微博，其中包括大量的实时拍摄的图片、视频等多媒体内容[2]。这种社会化媒体的传播，给多媒体的内容部署带来极大的冲击。在这种多媒体内容的产生和传播模式下，用户对媒体访问具有突发和时变的特性，使得现有多媒体内容部署和传输的策略，如内容分发网络（content delivery network，CDN）、对等传输（peer-to-peer，P2P）技术，缺少对内容访问的预知，无法有效降低系统资源消耗、快速响应用户请求。目前，如何有效服务海量的社会媒体内容，已经成为在线社会网络服务

商和多媒体内容提供商共同面临的巨大挑战。

内容流行度扁平化挑战传统媒体服务 在社会网络中，大量的社会关系基于现实生活圈产生，其中存在大量的小圈子。多媒体在这些小圈子中传播时，访问量虽然很低，但是远远高于传统媒体内容访问中冷门内容的流行度。这种模式使得社会媒体的流行度呈现扁平化（如Zipf（齐普夫定律）分布的参数从传统的0.7左右降到0.25）。由于社会媒体的内容流行度更加扁平，传统的CDN缓存策略会导致命中率下降30%以上[6]。这种扁平化的媒体内容流行度分布，给传统的内容服务带来巨大挑战。

社会媒体云计算

社会媒体计算对适应互联网大规模数据密集计算提出迫切需求，云计算的出现为社会媒体服务提供了新思路。

社会媒体云

使用云计算平台对社会媒体数据进行部署和传输的思路在工业界已有体现，例如，分布式云计算架构已经被应用到视频服务中，YouTube使用了谷歌分布在各地的云文件系统对视频内容进行分布式存储和服务[5]。为高效支持社会媒体服务，我们引入了“社会媒体云计算”概念。在社会媒体云计算框架下，系统架构采用云计算平台，通过互联网和移动互联网提供社会媒体应用服务，并拥有服务质量支持。社会媒体云计算主要研究如何使用云计算为社会媒体应用服务[13]。

当社会媒体采用云计算产生新的社会媒体云计算模式时，可以预见各种基于社会媒体云的社会媒体服务的出现。图1给出社会媒体云的服务框架——基于“基础设施即服务”的内容分发和“平台即服务”的数据挖掘，向用户提供各种社会媒体应用服务。

社会媒体应用服务 社会媒体云通过“软件即服务”的方式提供不同的社会媒体应用：即传播预测、内容推荐与搜索以及舆情分析。由于云计算提供分布式服务，不同区域的用户可以通过不同的

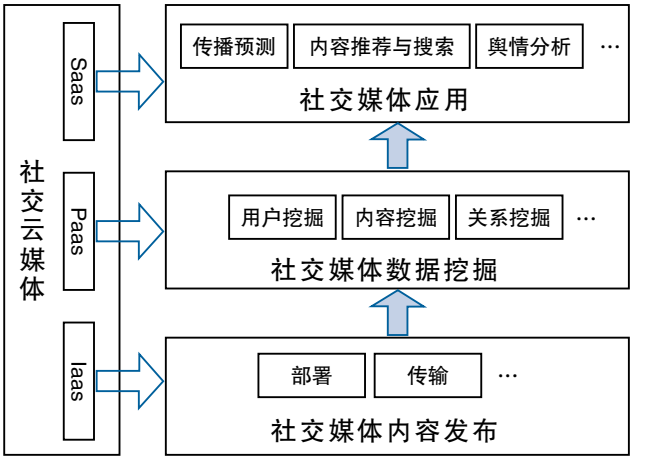

图1 社会媒体云的服务框架

平台使用这些服务。使用社会媒体云，可以大大降低应用提供商对数据处理以及应用维护的花费，例如，不同应用可以共享用户和内容数据；在社会媒体云中，不同的应用之间可以协作，使得用户获得更好的应用质量。

社会媒体数据挖掘服务 社会媒体云通过“平台即服务”模式提供不同的数据挖掘服务，包括：（1）用户挖掘，社会媒体云提供用户挖掘平台，用来帮助上层应用获得用户的兴趣、关系特性等信息；（2）内容挖掘，基于多媒体内容分析，如视频相似度分析等，提供有效的多媒体内容挖掘，用于上层对多媒体内容的描述；（3）关系挖掘，在社会媒体云中，提供关系挖掘平台，对社会关系图进行描述，用于上层应用掌握和预测用户的关系。通过云提供数据挖掘服务，可以大大降低数据处理的重复工作；上层应用可以直接利用数据挖掘的结果，从而大大降低新应用的成本。

社会媒体内容分发服务 社会媒体云通过“基础设施即服务”模式提供不同的分发服务，包括：（1）社会媒体内容部署，基于社会媒体云，完成对社会媒体的内容部署。社会媒体内容的流行度呈现扁平化，使得传统的缓存策略不再实用。因此，在社会媒体云设计中，对不同的内容和不同用户的社会圈子，采取不同的部署策略；（2）社会媒体内容传输，媒体内容在社会网络中传播的情况下，访问规模

或区域分布除了受到多媒体内容本身的影响外，还受到用户行为的影响。在对用户的传播行为进行研究之后，可以及时地将内容资源部署到离用户更近的边云（edge cloud）上，使得用户可以更快地访问和获取服务。利用社会媒体云的分发服务，其他社会媒体应用和服务可以专注于应用本身的质量保证，而将部署和传输等工作交给统一的分发服务。

社会媒体云资源分配

社会媒体云服务依赖于计算与通信资源。对社会媒体传播、访问特性的研究可以用于指导社会媒体云计算平台的设计。在线社会网络记录了用户的社会关系和他们对多媒体内容的使用行为（引入、传播和应用）[7]，这些信息可以用来推测社会网络用户的未来行为，这种预测在宏观上体现为全网或某一地域内的用户的整体行为趋势，对于优化云计算平台中计算资源和通信资源的分配具有指导意义[1]。

计算资源分配 在社会媒体云中，计算资源的分配需要根据社会媒体的服务特性，考虑以下指导策略：（1）减少服务瓶颈，不同的服务可能会成为其他服务和应用的先决条件。例如，大多数社会媒体应用依赖于数据挖掘服务，因此，数据挖掘需要分配更可靠的计算资源，从而尽可能地降低上层服务出现瓶颈的可能性，提高社会媒体云效率；（2）服务优先级，从用户的角度，不同的服务可能具有不同的优先级，例如，针对社会网络中的视频应用，其高优先级的服务为内容推荐、搜索等，将资源分配给优先级更高的服务和应用，可以优化特定服务和应用的质量；（3）计算资源与网络资源的协调分配，社会媒体应用通常通过网络对用户提供服务，这些应用需要一定的计算资源和网络资源的支持。协调通信和计算，例如同时考虑社会媒体数据生成需要的计算资源和传输需要的通信资源[15]，也是优化社会媒体云的重要方面。

通信资源分配 在通信资源的分配中，主要考虑网络的延迟与带宽。社会媒体云需要考虑以下因素来确定资源分配指导策略：（1）服务与应用的延迟敏感性，不同的社会化媒体服务和应用具有不同的延迟敏感性，例如，当用户使用内容推荐时，需要较短的延迟来满足实时请求；而静态数据的挖掘，则不需要很高的延迟保证，因为数据挖掘通常不直接服务于用户，而是服务于其他社会化媒体应用。不同的服务在通信资源分配时，需要根据服务和应用的延迟特征，决定不同类型的通信资源；（2）服务与应用的带宽敏感性，不同的社会化媒体服务和应用具有不同的带宽敏感性，例如，视频服务要传输视频流媒体，对带宽要求较高；而基于文本的社会化媒体应用，则对带宽要求较低。当部署不同的服务与应用时，需要为不同的服务与应用预留适当的带宽资源，从而在资源总量一定的情况下，满足不同类型的社会化媒体服务的要求。

结语

云计算的出现为社会媒体计算的发展带来了新的思路。随着社会化媒体应用的流行，社会媒体云计算将迎来发展的春天。■

朱文武

CCF会员。清华大学教授。主要研究方向为社会媒体计算、多媒体云计算、无线多媒体通信等。

wwzhu@tsinghua.edu.cn

崔　鹏

清华大学计算机系讲师。主要研究方向为社会网络分析与社会媒体计算。

cuip@tsinghua.edu.cn

王　智

清华大学计算机系博士生。研究方向为社会媒体云计算等。

wangzhi04@mails.tsinghua.edu.cn

参考文献

[1] Cui, P., Wang, F., & Yang, S. (2011). Item-Level Social Influence Prediction with Probabilistic Hybrid Factor Matrix Factorization. Twenty-Fifth AAAI Conference on Artificial Intelligence (AAAI).

[2] Cui, P., Wang, F., Liu, S., Ou, M., & Yang, S. (2011). Who Should Share What? Item-level Social Influence Prediction for Users and Posts Ranking. International ACM SIGIR Conference (SIGIR).
[3] Said, A. a. (2010). Putting things in context: Challenge on context-aware movie recommendation. the Workshop on Context-Aware Movie Recommendation.
[4] YouTube Global. (2012). Retrieved from http://youtube-global.blogspot.com/2012/01/holy- nyans-60-hours-per-minute-and-4.html
[5] Adhikari, V. a. (2010). Vivisecting youtube: An active measurement study.
[6] Cha, M., Mislove, A., & Gummadi, K. P. (2009). A Measurement-driven Analysis of Information Propagation in the Flickr Social Network. ACM WWW.
[7] Fabrício Benevenuto, T. R. (2009). Characterizing User Behavior in Online Social Networks. ACM IMC.
[8] Wang, Z., Sun, L., Yang, S., & Zhu, W. (2011). Prefetching Strategy in Peer-Assisted Social Video Streaming. in Proceedings of ACM Multimedia.
[9] 杨士强, 孙立峰, 崔鹏. Web社会网络分析. 中国计算机学会通讯, 第7卷, 第2期, 2011.
[10] Kilkki, K. (2008). Quality of experience in communications ecosystem. J. Universal Comput. Sci, 14, 615~624.
[11] Wang, Z., Sun, L., Wu, C., & Yang, S. (2012). Guiding Internet-Scale Video Service Deployment Using Microblog-based Prediction. IEEE INFOCOM Mini-Conference.
[12] Facebook Newsroom (2012): http://newsroom.fb.com/
[13] Zhu, W., Luo, C., Wang, J., & Li, S. (2011). Multimedia cloud computing. IEEE Signal Processing Magazine, 28, 59~69.
[14] Armbrust, M. a. (2009). Above the clouds: A berkeley view of cloud computing.
[15] Liao, j., Yuan, C., Zhu, W., Chou, P., Virtual Mixer: Real-Time Audio Mixing Across Clients and Cloud for Multi-Party Conferencing, ICASSP 2012.